

Problème d'optimisation sous contraintes

Conditions d'optimalité

Bo-Yuan HUANG

November 10, 2022

Plan

- 1 Introduction
- 2 Condition nécessaire d'optmialité
 - Théorème Karush-Kuhn-Tucker
 - Interprétation géométrique des conditions KKT
 - Qualification de contrainte
- 3 Conditions suffisantes d'optimalité
 - Cas 1 : Optimisation convexe
 - Cas 2 : Condition d'optimalité de second ordre
- 4 Dualité
 - Théorème de dualité
 - Interprétation géométrique
- 5 Application : un problème de classification par SVM

Problème d'optimisation

Un problème d'optimisation sous contraintes a pour forme générale :

$$(P) \quad \begin{cases} \min_x f(x) \\ g_i(x) \leq 0, i \in \mathcal{I} := \{1, \dots, m\} \\ h_j(x) = 0, j \in \mathcal{E} := \{1, \dots, p\} \\ f, g, h \text{ sont } \mathbb{R}^n \rightarrow \mathbb{R} \end{cases}$$

L'ensemble réalisable et le Lagrangien sont définis comme suite :

$$\mathcal{F} := \{x \in \mathbb{R}^n \mid g_i(x) \leq 0 \text{ for } i \in \mathcal{I}, h_j(x) = 0 \text{ for } j \in \mathcal{E}\}$$

$$\mathcal{L}(x, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \mu_j h_j(x)$$

Condition nécessaire d'optimalité

Théorème Karush-Kuhn-Tucker

Si $x^* \in \mathcal{F}$ est un minimum local pour le problème (P) et qu'une "certaine qualification de contrainte" est satisfaite, alors qu'il existe $\lambda \in \mathbb{R}_+^m$ and $\mu \in \mathbb{R}^p$ tel que:

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \mu_j \nabla h_j(x^*) = 0$$
$$\lambda_i g_i(x^*) = 0 \text{ for } i = 1, \dots, m$$

Interprétation géométrique des conditions KKT

Il existe $\lambda_1, \lambda_2 \in \mathbb{R}_+$ tel que: $\nabla f(x^*) + \lambda_1 \nabla g_1(x^*) + \lambda_2 \nabla g_2(x^*) = 0$




Figure: Condition de premier ordre

Interprétation géométrique des conditions KKT


Condition de relâchement supplémentaire: $\lambda_i g_i(x^*) = 0$ for $i = 1, \dots, m$

Si x^* est situé à l'intérieur de \mathcal{F} ,
 $g_i(x^*) < 0$, il suffit de choisir
 $\lambda_i = 0$ (contrainte inactive).

Si x^* est situé à la frontière de \mathcal{F} ,
 $g_i(x^*) = 0$, quelconque λ_i réalise
 $\lambda_i g_i(x^*) = 0$ (contrainte active).

On note l'ensemble des indices
 actifs :

$$\mathcal{A}(x^*) := \{i \in \mathcal{I} | g_i(x^*) = 0\}$$



Qualification de contrainte

En fait, pour utiliser le théorème KKT, il suffit d'assurer l'égalité du "cône linéarisant" et "cône tangent" (plus fort). Mais celle-ci est souvent difficile à réaliser.

On recherche avec compromis des conditions de la régularité appelées "qualification de contrainte" (QC) qui sont plus facile à vérifier .

Les QCs les plus couramment utilisés sont :

- 1 Slater : les g_i soient convexes, $\forall i = 1..m$ et $\exists \tilde{x} \in \mathcal{F}, g_i(\tilde{x}) < 0$.
- 2 Indépendance linéaire (QC-IL) : les vecteurs $(\nabla g_i(x^*) | i \in \mathcal{A}(x^*) \text{ et } (\nabla h_j(x^*) | j \in \mathcal{E})$ soient linéairement indépendents.

Cas 1 : Optimisation convexe

Précédemment, on a vu que les points de minimum local satisfont les conditions KKT. Si, de plus, les deux conditions suivantes sont vérifiées (optimisation convexe) :

- f et g_i sont convexes
- h_i sont linéaires (affines)

Alors les conditions KKT deviennent suffisantes et qu'un minimum local x^* trouvé avec KKT est un minimum global.

Si on trouve un point x^* satisfaisant KKT, mais la condition (1) ou (2) ci-dessus n'est pas vérifiée. Peut-t-on vérifier d'autre condition pour confirmer l'optimalité de x^* ?

Cas 2 : Condition d'optimalité de second ordre

Théorème : condition suffisante de second ordre

Si on a $x^* \in \mathcal{F}$ et $\lambda \in \mathbb{R}_+^m \geq 0$, $\mu \in \mathbb{R}^p$, qui vérifie les conditions KKT. Si on a de plus :

$$s^T \nabla_{xx}^2 L(x^*, \lambda, \mu) s > 0, \forall s \in \mathcal{F}_2$$

Alors x^* atteint un minimum local strict.

$$\begin{aligned} \mathcal{F}_2 &:= \{s \mid \nabla g_i(x^*)^T s \leq 0 \text{ for } i \in \mathcal{I}^0 \\ &\quad \nabla g_i(x^*)^T s = 0 \text{ for } i \in \mathcal{I}^+ \\ &\quad \nabla h_j(x^*) = 0 \text{ for } j \in \mathcal{E}\} \end{aligned}$$

où $\mathcal{I}^+ = \{i \mid \lambda_i > 0, \text{ for } i \in \mathcal{I}\}$ $\mathcal{I}^0 = \{i \mid \lambda_i = 0, \text{ for } i \in \mathcal{I}\}$

Dualité

Etant donné le problème primaire (P), quitte à convertir les contraintes d'égalité en inégalité, on introduit le problème (P') :

$$(P') \quad \begin{cases} \min_x f(x) \\ g_i(x) \leq 0, i \in \mathcal{I} := 1, \dots, m \\ x \in X \end{cases}$$

X pourrait être R^n , Z^n , Z_+^n ou bien $\{0, 1\}^n$ qui rend le problème compliqué à résoudre.

Dualité

Pourquoi considère-t-on le problème dual ?

L'optimum du problème primaire (P), noté $v(P)$ peut être difficile à résoudre. Le problème dual (D) est un problème fortement lié au problème primaire, il est toujours convexe donc plus simple à résoudre. Résoudre le problème dual nous aide à analyser le problème primaire, voire dans certains cas, à résoudre le problème primaire.

Construction du problème dual

On définit la fonction duale de Lagrange pour tout $\lambda \in \mathbb{R}_+$:

$$d(\lambda) = \min_{x \in X} L(x, \lambda) = \min_{x \in X} \{f(x) + \lambda g(x)\},$$

on a

$$d(\lambda) \leq \min_{x \in \mathcal{F}} \{f(x) + \lambda g(x)\} \leq \min_{x \in \mathcal{F}} f(x) = v(P)$$

Construction du problème dual

On en déduit $\forall \lambda \geq 0, d(\lambda) \leq v(P)$, qui donne une borne inférieure au problème (P). On s'intéresse donc à pousser la borne inférieure vers le haut pour "serrer" l'inégalité, donc on considère le problème :

$$(D) \quad \begin{cases} \max_{\lambda} d(\lambda) = \max_{\lambda} \min_{x \in X} L(x, \lambda) \\ \text{s.t. } \lambda > 0, i \in \mathcal{I} := 1, \dots, m \end{cases}$$

On verra qu'il est possible de reformuler le problème (P') en

$$\min_{x \in X} \max_{\lambda \geq 0} L(x, \lambda)$$


Théorème de dualité

On note $v(D)$ l'optimum du problème (D).

Théorème de dualité faible

On a $\forall x \in \mathcal{F}, \lambda \geq 0$


$$d(\lambda) \leq v(D) \leq v(P) \leq f(x)$$



Théorème de dualité

Théorème de dualité forte

Si la qualification de contrainte Slater est vérifiée pour un problème convexe (P), on a $\exists \lambda \geq 0, x \in \mathcal{F}, d(\lambda) = v(D) = v(P) = f(x)$



Interprétation géométrique

Pour visualiser le domain de valeur de f et g , on introduit

$$G = \{(y, z) | g(x) = y, f(x) = z, x \in X\}$$



On rappelle que

$$(P') \quad \begin{cases} \min f(x) \\ \text{s.t. } g(x) \leq 0, x \in X \end{cases}$$

$$(D) \quad \begin{cases} \max_{\lambda \geq 0} d(\lambda) \\ d(\lambda) = \min_{x \in X} \{f(x) + \lambda g(x)\} \end{cases}$$


Interprétation géométrique

Soit $\alpha = z + \lambda y$, $-\lambda$ est la pente et α est l'intercept. Si G est convexe :



Interprétation géométrique

Soit $\alpha = z + \lambda y$, λ est la pente et α est l'intercept. Si G n'est pas convexe :



Interprétation géométrique

Réflexion 1

Si on trouve un point $\bar{x} \in \mathcal{F}$, $\lambda \geq 0$ tels que $d(\lambda) = f(\bar{x})$

Comme $d(\lambda) \leq v(D) \leq v(P) \leq f(\bar{x})$, on aura alors $v(P) = v(D)$ et \bar{x}, λ sont l'optimum de (P) et de (D)

Réflexion 2

- Si $v(P) = -\infty$, alors $d(\lambda) = -\infty, \forall \lambda \geq 0$
- Si $v(D) = +\infty$, alors $v(P) = +\infty$, c'est-à-dire, (P) n'a pas de solution réalisable

Classification par SVM

Problème classification de tumeur

On dispose de 699 points de données (x_i, y_i) , $i = 1..699$, avec 9 dimension pour chaque x_i , et $y_i \in \{1, -1\}$

Approche SVM

Trouver un hyperplan decrit par $\langle \omega, x \rangle + \beta = 0$ avec $\langle \omega, x_i \rangle + \beta \geq 1$ si $y_i = 1$ et $\langle \omega, x_i \rangle + \beta \leq -1$ si $y_i = -1$ pour separer les points x_i dans deux groupes.

Classification par SVM

Problème optimisation quadratique


Maximiser la "marge" (distance) $2/\sqrt{\langle \omega, \omega \rangle}$ entre les deux hyperplans
 $\langle \omega, x \rangle + \beta = 1$ et $\langle \omega, x \rangle + \beta = -1$

$$\begin{cases} \min_{\omega} \frac{1}{2} \langle \omega, \omega \rangle \\ \text{s.c. } y_i (\langle \omega, x_i \rangle + \beta) \geq 1, i = 1..m \end{cases}$$

SVM - Soft margin

Pour éviter les cas des points "inséparables", on introduit les terms de pénalités ξ_i et C . Le problème d'optimisation avec "soft margins" est formulé comme le suivant:

$$(P) \quad \begin{cases} \min_{\omega, \xi} f(\omega, \xi) = \frac{1}{2} \langle \omega, \omega \rangle + C \sum_{i=1}^m \xi_i \\ y_i(\langle \omega, x_i \rangle + \beta) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i \in \{1, \dots, m\} \end{cases}$$



On remarque que dans (P), f et g sont convexes, et que la condition Slater est satisfaite.

SVM - Soft margin

Lagrangien du problème avec pénalité est

$$\begin{aligned}\mathcal{L} &= \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \lambda_i (1 - \xi_i - y_i (\omega^T x_i + \beta)) + \sum_{i=1}^m \mu_i (0 - \xi_i) \\ &= \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \lambda_i (y_i (\omega^T x_i + \beta) - 1 + \xi_i) - \sum_{i=1}^m \mu_i \xi_i\end{aligned}$$

En prenant les dérivées par rapport à ω, β et ξ_i

$$\partial_{\omega} \mathcal{L} = \omega - \sum_{i=1}^m \lambda_i y_i x_i = 0 \Rightarrow \omega = \sum_{i=1}^m \lambda_i y_i x_i$$

$$\partial_{\beta} \mathcal{L} = \sum_{i=1}^m \lambda_i y_i = 0$$

$$\partial_{\xi_i} \mathcal{L} = C - \lambda_i - \mu_i = 0$$

SVM - Soft margin

En remplaçant ω , on obtient la fonction duale:

$$\begin{aligned}\mathcal{L}_{dual} &= \frac{1}{2} \|\omega\|^2 - \omega^T \left(\sum_{i=1}^m \lambda_i y_i x_i \right) - \beta \sum_{i=1}^m \lambda_i y_i + \sum_{i=1}^m \lambda_i + \sum_{i=1}^m (C - \lambda_i - \mu_i) \xi_i \\ &= \sum_{i=1}^m \lambda_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \lambda_i \lambda_j y_i y_j x_i^T x_j\end{aligned}$$

Le problème dual s'écrit donc :

$$\begin{cases} \max_{\lambda} \mathcal{L}_{dual} = \sum_{i=1}^m \lambda_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \lambda_i \lambda_j y_i y_j x_i^T x_j \\ 0 \leq \lambda_i \leq C, i \in \{1, \dots, m\} \\ \sum_{i=1}^m \lambda_i y_i = 0 \end{cases}$$

SVM - Solution numérique

Application du théorème de dualité forte

Grâce à la condition Slater qui est vérifiée, la solution du problème dual λ est telle que $\mathcal{L}_{dual}(\lambda) = \mathcal{L}(\omega, \xi, \lambda)$

On résout les λ_i du problème dual (convexe) grâce à un solveur. On peut ensuite obtenir

$$\omega = \sum_{i=1}^m \lambda_i y_i x_i$$

$$\beta = y_i - \langle \omega, x_i \rangle, \text{ si } 0 < \lambda_i < C$$

On arrive finalement au classifieur : $f(x) := \text{sign}\{\langle \omega, x \rangle + \beta\}$

SVM - Solution numérique

Table: Prediction results on testing sample (563 points)

		Predicted	
		Negative	Positive
Actual	Negative	True negative = 376	False positive = 3
	Positive	False negative = 46	True positive = 138

Table: Indicateurs clés

Precision	Recall	F1 score
$\frac{TP}{TP+FP}$	$\frac{TP}{TP+FN}$	$2 \times \frac{Precision \times Recall}{Precision + Recall}$
$\frac{138}{138+3} = 97.87\%$	$\frac{138}{138+46} = 75\%$	$2 \times \frac{0.9787 \times 0.75}{0.9787 + 0.75} = 84.9\%$

Merci pour votre attention